

Aplicação de Machine learning e séries temporais para previsão de demanda: um estudo de caso em uma empresa de bens de consumo

Application of Machine learning and time series for demand forecasting: a case study in a consumer goods company

DOI:10.34117/bjdv9n8-001

Recebimento dos originais: 03/07/2023

Aceitação para publicação: 02/08/2023

Guilherme Gomes

Mestre em Logística

Instituição: Universidade Federal de Santa Catarina

Endereço: Carvoeira, Florianópolis, Santa Catarina, CEP: 88040-535

E-mail: guilhermegomes_19@hotmail.com

Ana Lígia Vieira Rodrigues

Mestre em Logística

Instituição: Universidade Federal de Santa Catarina

Endereço: Carvoeira, Florianópolis, Santa Catarina, CEP: 88040-535

E-mail: anar2703@gmail.com

Marina Bouzon

Doutora em Engenharia de Produção

Instituição: Universidade Federal de Santa Catarina

Endereço: Carvoeira, Florianópolis, Santa Catarina, CEP: 88040-535

E-mail: marinabouzon@gmail.com

Francielly Hedler Staudt

Doutora em Engenharia de Produção

Instituição: Universidade Federal de Santa Catarina

Endereço: Carvoeira, Florianópolis, Santa Catarina, CEP: 88040-535

E-mail: francielly.hedler.staudt@ufsc.br

RESUMO

O objetivo deste trabalho é impulsionar a acuracidade da previsão de demanda de uma empresa de bens de consumo, através da implementação de modelos de séries temporais e “machine learning”. Metodologia: Para tal, foram coletados os históricos de vendas da empresa num horizonte de cinco anos, posteriormente foi realizado uma análise exploratória de dados, realizada a limpeza dos outliers, treinados diversos modelos de séries temporais e “machine learning”, testados os resultados de acuracidade, e selecionado o melhor modelo para cada produto para se realizar a previsão de demanda. Resultados: Obteve-se uma redução no erro médio da previsão de vendas em 19 pontos percentuais, o que possibilitou redução de estoque de 21% e aumento no nível de serviço ao cliente em 7%. Limitações: A pesquisa focou na primeira fase do processo de S&OP que consiste em prever demanda. Neste estudo focou-se em aplicação de métodos de séries temporais de Machine learning para aumentar a acuracidade deste processo. Implicações Práticas: Comprovou-se, dessa forma, que os modelos de séries temporais e “machine learning” possuem resultados significativamente mais atraentes no processo de

planejamento de demanda do que modelos simples de médias móveis e suavizações. Originalidade: A partir de revisão de literatura, percebe-se que ainda há um gap de estudos aplicando métodos de séries temporais e Machine learning no processo de S&OP, dessa forma essa pesquisa busca impulsionar sua aplicação através dos resultados obtidos.

Palavras-chave: planejamento de demanda, previsão de vendas, sales and operations planning, prever.

ABSTRACT

Gol: The objective of this work is to boost the accuracy of the demand forecast of a consumer goods company, through the implementation of time series models and machine learning **Methodology:** To this end, the company's sales histories were collected over a five-year horizon, then an exploratory data analysis was performed, the outliers were cleaned, several time series models and machine learning were trained, the accuracy results were tested, and the best model for each product was selected to perform the demand forecast **Results:** A reduction in the average error of the sales forecast was obtained by 19 percentage points, which allowed a reduction of inventory of 21% and an increase in the level of customer service by 7%. **Limitations of the investigation:** The research focused on the first phase of the S&OP process, which consists of forecasting demand. This study focused on the application of machine learning time series methods to increase the accuracy of this process. **Practical implications:** It has been proven that time series models and machine learning have significantly more attractive results in the demand planning process than simple models of moving averages and smoothings. **Originality/Value:** From a literature review, it is clear that there is still a gap in studies applying time series methods and Machine learning in the S&OP process, so this research seeks to boost its application through the results obtained.

Keywords: demand planning, sales forecasting, sales and operations planning, forecasting.

1 INTRODUÇÃO

Com o advindo da globalização e da tecnologia que conecta todas as partes do mundo em tempo real, os consumidores passam a ter informações com qualidade e velocidade antes não vistas, que acarretam na mudança do comportamento de consumo muito rapidamente, tornando a demanda do mundo industrial muito incerta, requerendo intensas atividades de planejamento integrado e avançado internamente e externamente nas organizações (OLIVIA, WATSON, 2011).

Para Christopher (2011), para que as empresas possam prosperar nesta conjuntura torna-se fundamental antecipar os anseios do mercado com a melhor qualidade possível, num horizonte satisfatório, capaz de proporcionar às empresas, qualidade de informação e tempo hábil para realizarem os ajustes da cadeia de suprimentos de forma a galgar vantagens competitivas. Entretanto, planejar a demanda com confiabilidade é grande

desafio. Um dos princípios da previsão de demanda é que ela nasceu para errar, dessa forma, o um grande diferencial competitivo é prever a demanda melhor que os concorrentes (WALLACE, STAHL, 2003).

Um bom planejamento de demanda é a base para o processo de S&OP, “Sales and Operations Planning”. Oriundo dos Estados Unidos, o S&OP é um processo que através de um ciclo, geralmente mensal, obtiva planejar de forma integrada as diversas funções empresariais, proporcionando uma série de benefícios, no âmbito tático, ou seja, médio prazo (Seeling et al., 2019). Está integração ocorre de maneira multifuncional e deve conectar, não apenas vendas e operações, mas também diferentes funções de operações entre si, com intuito de definir uma capacidade geral de entrega. (Ohlson et al., 2021)

Dentro do S&OP, o principal input é o planejamento de demanda, com diferentes níveis de granularidade. A partir dessa informação, são desdobrados os demais planos na cadeia de suprimentos, como planos de produção, compras, estoques, transportes, armazenagem, movimentação, etc. (Lapide, 2004). Para uma análise profunda da demanda e para determinar as capacidades de fornecimento, o processo de S&OP produz uma previsão de demanda para todo o portfólio de produtos, tanto os atuais como os lançamentos de novos produtos, de uma maneira agregada por família de produtos (Seeling et al. 2019).

O subprocesso de planejamento de demanda pode ser segregado entre a previsão quantitativa e a previsão qualitativa. A previsão quantitativa é composta pela base matemática, que consiste na observação de dados históricos de demanda para prognóstico do futuro com base em métodos estatísticos aplicados (Ohlson et al., 2021). Vem se notando durante últimas décadas que há uma grande dificuldade para as empresas conseguirem aplicar adequadamente métodos científicos para analisar o passado e prever o futuro (Nicolas et al., 2021). Essas dificuldades são originárias de alguns motivos, entre os quais pode-se destacar: baixa qualificação da mão-de-obra, necessidade de investimento em tecnologia, baixo nível de maturidades dos processos de planejamento, dentre outras (Kristensen & Jonsson, 2018).

O ponto de partida do processo de S&OP é a previsão de demanda, se a precisão dessa previsão puder ser melhorada, o planejamento da demanda será aprimorado, bem como as operações e estoques; e como consequência, tanto o cliente quanto a empresa se beneficiarão (OHLSON et al., 2021). Para aumentar os lucros da empresa e reduzir custos, uma previsão de vendas eficaz é primordial para então conseguir o melhor gerenciamento de estoques, vendas e compras (CHEN & LU, 2017)

A utilização de técnicas de *analytics* não é um fenômeno novo e já é utilizada há alguns anos no contexto das cadeias de suprimentos (SOUZA, 2014) e também em abordagens dentro do processo do S&OP (LIM et al., 2017; BEN ALI et al. 2019).

Atualmente, utilizando linguagens de programação com interface planejada para ser mais intuitiva, como por exemplo R e Python, é possível programar, com moderado nível de dificuldade e preparação prévia, modelos algoritmos de “machine learning” e “deep learning”, capazes de entregar significativa melhoria na acuracidade da previsão quantitativa, em comparação com modelos executáveis apenas em Microsoft Excel, principal ferramenta utilizada na atualidade para esta finalidade (Coelho, Richert, 2015). Dessa forma, as empresas aumentam sua probabilidade de performar melhor em termos de nível de serviço ao cliente, estoques mais balanceados, custos operacionais mais otimizados, fluxo de caixa mais saudável, dentre outros benefícios sob diversos espectros (Nicolas et al., 2021).

Devido a grande quantidade de dados que precisam ser processadas, é notável a rápida ascensão da tecnologia da informação (TI) para que se obtenha resultados de uma forma mais rápida e confiável, pois é amplamente argumentado que se tenha cada vez mais frequente a tomada de decisão orientada a dados. (KLEIN et al., 2018). A aquisição e utilização de TI no contexto do S&OP têm um impacto positivo da performance e desempenho da cadeia de suprimentos (GOH & ELDRIDGE, 2019). Apesar de diferentes visões sobre a aplicação de TI no S&OP, grande parte dos estudos apresentam um impacto positivo dessa relação. Dessa forma, para uma maior integração e melhores benefícios para o desempenho da empresa depende da maturidade do processo de S&OP (NICOLAS et al., 2021).

Para um processo de S&OP eficaz e maduro, pode ser considerado um pré-requisito a utilização de TI (Grimson et al., 2007). Mesmo que existam estudos dizendo que a TI pode funcionar como um facilitador e uma barreira para o S&OP (Pedroso et al., 2016), a maioria dos estudos conclui que a TI é um facilitador para um S&OP eficaz. Ohlson et al. (2021) apresentou em seu artigo que a utilização de técnicas mais avançadas de TI, Machine Learning (ML) são raramente utilizadas no S&OP. Essas técnicas são mais utilizadas nas previsões de demanda. Como o processo de S&OP demanda e trata uma grande quantidade de dados, as técnicas de ML podem ser utilizadas para encontrar padrões e dessa forma mitigar riscos para a tomada de decisão. Ohlson et al. (2021) ainda comentam que há uma lacuna na literatura sobre o uso de ML no processo de S&OP. Nicolas et al. (2021) citam que há uma lacuna na literatura sobre a aplicação de *Big Data*

Analytics (BDA) e suas aplicações no processo de S&OP. O BDA surgiu recente como uma nova área de pesquisa em forte extensão e com influência positiva e significativa dentro do processo do S&OP (Mishra et al., 2016). Estas evidências mostram que o BDA ainda não foi aplicado ao S&OP (NICOLAS et al., 2021). Em resumo, a combinação de técnicas de BDA e ML fornecem significativos e confiáveis insights para a tomada de decisão (CADAVID et al., 2018)

Desta maneira, os objetivos desta pesquisa são:

- Definir modelos de ML e séries temporais aplicados aos processos de planejamento de demanda;
- Aplicar e testar a acuracidades dos modelos de ML e séries temporais em uma empresa de bens de consumo;
- Comparar a acuracidade dos modelos e propor sua utilização no processo de S&OP.

2 METODOLOGIA

2.1 CLASSIFICAÇÃO DA PESQUISA

A presente pesquisa pode ser classificada como uma pesquisa aplicada, pois está dedicada a gerar conhecimento através da solução de problemas específicos (NASCIMENTO E SOUSA, 2016); quanto sua abordagem pode ser considerada qualitativa e quantitativa. Em relação aos objetivos da pesquisa pode ser considerada uma pesquisa exploratória, segundo Gil (2002), “é uma pesquisa onde o pesquisador irá se familiarizar com o problema com o intuito de criar hipóteses”. No final, em relação ao procedimento de pesquisa é caracterizada por estudo de caso.

2.2 ETAPAS DA PESQUISA

Para este estudo foram separadas 3 etapas de pesquisa. A primeira etapa focou em buscar na literatura modelos de séries temporais (ST) e ML aplicados para previsão de demanda. A segunda etapa consistiu em aplicar os métodos estatísticos selecionados na etapa 1, que vai desde obter e tratar os dados históricos de demanda até a aplicação dos métodos de séries temporais e ML para prever demanda. Por fim, a terceira etapa consistiu em avaliar os resultados dos métodos estatísticos de previsão e propor qual método a empresa deve utilizar para aumentar a acuracidade do seu processo.

2.3 EMPRESA ESTUDADA

O trabalho foi realizado em uma empresa do ramo de bens de consumo, de médio porte, com presença comercial em todo o território nacional, possuindo mais de 50 anos de trajetória.

Seu portfólio abrange mais de 300 produtos em fase de comercialização, com aproximadamente 20% de renovação anual do portfólio de produtos. Os produtos são comercializados através de uma estrutura multicanal, com características bem diferenciadas no padrão de compra e exigência de nível de serviço. Em linhas gerais, a grande maioria da carteira de clientes da empresa deseja o faturamento do pedido imediato ao momento da compra, com poucos casos de cliente que apresentam intenção de programar de entregas ao longo do tempo.

No que tange a lead times, o ciclo mais longo é o de desenvolvimento de produtos, que pode levar até 12 meses, e há grande incidência de matéria-prima importada, com lead times acordados com fornecedores que podem chegar até 120 dias. A estrutura industrial é bastante verticalizada, possuindo várias estruturas operativas dentro de um parque industrial localizado na região sul do Brasil, de onde é também centralizada a expedição dos pedidos.

A empresa passa por momento de significativa transformação, buscando tornar sua estrutura “demand-driven” ou “cliente-centric”, uma vez que sua história e o guia para tomada de decisões importantes costumemente estão baseada no melhor para sua operação industrial. Nesse sentido, busca a transformação digital para apoiar o processo decisório dirigido para dados, que busca em sua cadeia de suprimentos apoiar a empresa a resolver o “trade off” entre capital de giro e nível de serviço ao consumidor.

No contexto atual, a empresa enfrenta significativos desafios para melhorar o nível de serviço ao cliente, onde seu indicador de OTIF (On Time In Full) apresenta valores abaixo de 60% no passado recente. Ao mesmo tempo, existe uma dificuldade eminente na empresa para administrar o fluxo de caixa, onde o indicador de giro financeiro ultrapassa 8 meses de necessidade de capital de giro para suportar a operação.

Sabendo que sua cadeia de suprimentos é verticalizada, com insumos oriundos de importação, a empresa aposta que a melhoria da acuracidade no seu planejamento e no aumento da sua capacidade de previsibilidade na cadeia de suprimento como fator determinante para superar o trade off estabelecido. Dessa forma, decidiu-se investir na implementação do processo de S&OP, “Sales and Operations Planning”, e buscar alternativas para aumentar a acuracidade dos planos de vendas, cujos resultados estavam

na casa de 40% de acuracidade e 60% de desvio, de acordo com o orçamento anual, que até o momento, era a principal ferramenta de planejamento da empresa.

3 DESENVOLVIMENTO

3.1 MÉTODOS DE ST E ML APLICADOS A PREVISÃO DE DEMANDA

A combinação de ML e BDA pode trazer benefícios, aos serem acoplados, criam modelos de previsão mais completos e transformam a informação em conhecimento útil (CADAVID et al.,2018). Com o objetivo de refletir a real demanda do mercado, a previsão de demanda utiliza dados em que os efeitos de promoções e/ou escassez é corrigido (CADAVID et al., 2018). Sendo um dos elementos principais do processo de S&OP, a previsão de demanda tem o objetivo de coordenar todos os integrantes da cadeia de suprimentos, de tal forma a reduzir o atraso de informações entre cliente final e fornecedores. Desta forma é possível obter as seguintes vantagens como: mitigação do efeito chicote, melhor aproveitamento dos recursos e planejamento da cadeia, redução de falta de estoques e excesso de custos (SCAVARDA et al. 2017).

Prever demanda pode ser considerado um problema complexo, principalmente se ocorrer falta e/ou ausência de dados, ou ainda, conter valores atípicos. Históricos de vendas podem ser considerados ST e atualmente podem ser encontrados diferentes modelos já desenvolvidos por Holt-Winters, ARIMA, SARIMA, SARIMAX, GARCH, etc (PAVLYSHENKO, 2019). A aplicação prática apresenta que a utilização de regressão quando comparada com ST pode apresentar melhores resultados, pois os algoritmos de ML conseguem encontrar padrões nos modelos de ST. (SHERSTINSKY,2020). É possível encontrar mesmo padrões complexos nos históricos de previsão de vendas através da utilização de modelos supervisionados de ML, sendo os mais populares os algoritmos de Random Forest e Tree-based ML. (JAMES et al. 2013). A tabela 1 apresenta alguns dos algoritmos de ML aplicados a previsão de demanda.

Tabela 1 – Algoritmos de ML aplicados a previsão de demanda

Nome do Método	Referência
T Time series variables (Past demand or sales values)	
ELM Extreme Learning Machine	Hang et al., 2015
ANN Artificial Neural Network (with Back-propagation learning)	Rumelhart et al.,1986
DT Decision Trees	Hunt et al., 1966
KNN K-nearest-neighbor	Fix & Hodges, 1951
RF Random forests	Tin Kam Ho, 1995
SVM Support Vector Machine (In the regression form)	Boser et al., 1992
CNN Convolutional Neural Network	LeCun et al., 1999
LSTM Long Short-Term Memory	Hochreiter & Schmidhuber, 199
SRA Stepwise regression analysis	

3.2 APLICAÇÃO DOS MÉTODOS ESTATÍSTICOS PARA PREVER DEMANDA

Para isso, desenhou-se um modelo de trabalho, que segue 8 etapas de construção da previsão de demanda, seguindo os modelos utilizados por Pavlyshenko (2019) e Schmidt (2021) conforme ilustra a figura 1. Todos os cálculos e análises foram realizadas utilizando o software Python e os principais pacotes aplicados nos modelos foram: *pandas*, *sklearn*, *numpy*, *keras*, *matplotlib*, *seaborn*.

Figura 1. Etapas para aplicar os métodos estatísticos



Fonte: Dados originais da pesquisa

3.2.1 Obtenção de dados

Estabeleceu-se uma planilha eletrônica padronizada, de onde foram coletadas diversas informações do histórico de demanda da empresa. As informações foram obtidas com alto grau de granularidade, abrangendo todos os pedidos de vendas que a empresa recebeu durante os últimos 5 anos. Para a aplicação dos métodos de TS é necessário um longo período de histórico para capturar a sazonalidade (PAVLYSHENKO, 2019).

Para cada pedido, foram coletadas informações que podem colaborar na modelagem estatística, como por exemplo: data de emissão, data desejada de entrega, quantidade solicitada, valor unitário, valor total, canal de vendas, cadastro do cliente, cadastro do representante, localidade, dentre outros. É importante destacar que os dados obtidos da empresa foram da demanda e não do faturamento ou entrada de pedidos. É importante esclarecer que o processo de S&OP requer a manipulação de dados históricos de demanda, na sua forma mais irrestrita possível. Se fossem utilizados dados de faturamento para a previsão da demanda futura, partiria-se de um patamar de demanda já restrito pela capacidade da companhia de faturar os pedidos, levando em consideração possíveis problemas e restrições de produção, de suprimentos, de logística, ou outros quaisquer descompassos que acontecem comumente nas empresas que fazem com que os pedidos sejam, em partes, entregues com atraso. Como o grande objetivo de processo S&OP é balancear a demanda e a oferta no futuro, a médio prazo, é extremamente importante que a empresa planeje ao futuro a demanda que realmente espera que o

mercado possa demandar, sem considerar quaisquer restrições ou limitações, pois na terceira fase do ciclo S&OP será justamente confrontada a demanda contra as capacidades, e a partir dessa análise serão desenvolvidos cenários para aumento de capacidades e resolução de descompassos em termos de excesso de demanda ou falta de oferta. Se a empresa captura os dados históricos já restritos de demanda e alimenta os modelos estatísticos com estes dados, a tendência é que a demanda projetada já detecte as restrições e não projete a demanda irrestrita desejada. Dessa forma, na empresa estudada, a melhor maneira encontrada para resolver tal situação foi considerar a data desejada de faturamento dos pedidos pelos clientes, e não a data de emissão do pedido ou a data de faturamento dos mesmos.

3.2.2 Análise exploratória de dados

Após a coleta dos dados, e antes da sua utilização na modelagem, realizou-se uma análise exploratória de dados, com objetivo de desvendar padrões de demanda e características de vendas que pudessem, posteriormente, serem utilizadas como guia para a modelagem das ST e modelos de ML. Para grande parte dos métodos populares e tradicionais de previsão, é exigido que o conjunto de dados seja estacionário, desta maneira a média e variância devem ser as mesmas em todo o histórico de dados, eliminando assim qualquer tendência ou sazonalidade (SCHMIDT et al., 2022).

Aferiu-se os padrões de média de venda, desvio padrão do comportamento diário, coeficiente de variação, grau de estabilização da demanda dos produtos entre os canais de vendas, o grau de intermitência de demanda entre os produtos, clientes mais representativos.

Verificou-se que o coeficiente de variação da demanda por produto, que é o desvio padrão do histórico dividido pela média de demanda, resultou de forma ponderada pelo volume em 81%. O coeficiente de variação é um indicador para identificar os níveis de oscilação da demanda. Ou seja, quanto maior o coeficiente de variação, entende-se que o produto apresenta um histórico mais instável, com maior presença de vales e picos, e por consequência, apresenta um grau maior de dificuldade para a previsão de demanda. Dito em outras palavras, o coeficiente de variação é uma maneira de expressar a variabilidade dos dados tirando a influência da ordem de grandeza dos mesmos. A tabela 2 estratifica o coeficiente de variação por produto do portfólio, onde percebe-se que a maior parte dos produtos apresenta um coeficiente de variação entre 50% e 100%:

Tabela 2. Coeficiente de variação

Coeficiente de Variação	% dos DFU's
até 30%	1%
até 50%	9%
até 100%	59%
acima de 100%	32%

Fonte: Dados originais da pesquisa

Constatou-se também que a intermitência da demanda por produto, que é o número de períodos totais analisados dividido pelo número de períodos que houve demanda, ou seja, a demanda foi diferente de 0 (zero), resultou de forma ponderada em uma intermitência de 3,10. Isso significa, que, em média, a cada 10 períodos de tempos consecutivos na série histórica, aproximadamente apenas 3 períodos tiveram presença de demanda, nos outros aproximadamente 7, não houve demanda para o produto. A tabela 3 estratifica a intermitência por produto do portfólio, onde observa-se que 60% do portfólio de produtos apresenta intermitência de até 2,0:

Tabela 3. Grau de intermitência

Intermitência	% dos DFU's
até 1,5	27%
até 2	32%
até 3	19%
acima de 3	21%

Fonte: Dados originais da pesquisa

3.2.3 Tratamento de outliers

Os históricos de vendas podem ter muitos outliers ou dados faltantes. Desta forma é essencial fazer uma limpeza nos dados antes de aplicar os modelos de TS ou ML (PAVLYSHENKO, 2019).

Fator importante antes da modelagem é a limpeza do histórico dos dados. Por este motivo, foi realizada uma análise dos dados retirando os outliers, através de uma técnica conhecida como Winsorização. Para Sang e Jong (2017), a técnica consiste em separar os dados em quartis, onde o primeiro quartil representa 25% dos valores mais baixos encontrados na amostra, o segundo quartil equivale a 50%, o terceiro a 75% e o último quartil os 25% dos dados mais altos da amostra. Posteriormente, calcula-se a diferença entre o valor limite do primeiro quartil para o terceiro quartil, o que representa o intervalo interquartil. Soma-se e diminui-se o intervalor interquartil multiplicado por 1,5, convencionalizado, e obtém-se os limites para detecção dos outliers, sendo que os dados que estiverem fora destes limites são considerados como os outliers da amostra. A partir disso,

a técnica da Winsorização prega a substituição dos outliers pelo limite superior ou inferior calculado anteriormente, de acordo com a característica do dado, pico ou vale.

Dessa forma, obteve-se uma base de dados com menor grau de variabilidade e portanto, mais apropriada para a aplicação dos modelos estatísticos. A tabela 4 demonstra o coeficiente de variação após winsorização, que no total ponderado reduziu para 55%:

Tabela 4. Coeficiente de Variação após Winsorização

Coeficiente de Variação	% dos DFU's
até 30%	10%
até 50%	37%
até 100%	52%
acima de 100%	1%

Fonte: Dados originais da pesquisa

3.2.4 Treinamento de modelos

Com uma base de dados com mais de 200.000 instâncias em um horizonte de 5 anos de histórico de demanda, foi possível separar os dados em 2 “datasets”, sendo 1 para treino e outro para teste dos modelos.

Para o “dataset” de treino foi estipulado os 3 primeiros, ou mais antigos, anos do histórico de demanda. Portanto, para o “dataset” de teste foram determinados os 2 anos mais recentes do histórico de demanda. Segundo Tugay e Ögüdücü (2017), grande parte dos trabalhos executados com modelos de “machine learning” aplicam a divisão da base em 70% para treino e 30% para teste, o que faz sentido com a metodologia adotada neste estudo.

3.2.5 Teste dos modelos

Significativa diferença na utilização de linguagens de programação, como Python ou R, em estudos de predição de demanda, é a capacidade de teste de inúmeros modelos estatísticos com alta velocidade e capacidade de análise, o que, através de planilhas eletrônicas, comumente utilizadas no processo de planejamento de demanda nas empresas, não é possível, na maioria dos casos. Segundo Ohlsn et al. (2021) a escolha da técnica de ML e onde ela deve ser usada, está conectada a muitos fatores, por exemplo, a qualidade e o tamanho dos dados disponíveis, o número de recursos, a complexidade da tarefa, os requisitos operacionais em tempo real, o poder computacional precente, etc.

Neste estudo, foram calibradas 30 metodologias estatísticas de séries temporais e “machine learning” para cada “Demand Forecast Unit” [DFU]: “Simple average”, “Simple moving average”, “Weighted average”, “Weighted moving average”, “Single

exponential smoothing”, “Double exponential smoothing (Holt) ”, “Triple exponential smoothing (Winters) ”, “Automated exponential smoothing”, “Croston method”, “Multiple linear regression”, “ARIMA model (Box-Jenkins)”, “Demand sensing algorithm”, “Bass Difusion”, “Linear Regression”, “Multiple Regression”, “KNN”, “Naive Bayes”, “SVM”, “Random Forest”, “XGBoosting”, “LSTM”, “Multi-Layer Perceptron (MLP)”, “Bayesian Neural Network [BNN] ”, “Radial Basis Functions [RBF] ”, “Generalized Regression Neural Networks [GRNN] ”, “K-Nearest Neighbor regression [KNN]”, “CART regression trees [CAR]”, “Support Vector Regression [SVR]”, “Gaussian Processes [GP] ”, “Prophet (Facebook)”.

3.2.6 Seleção de modelo por DFU

Para seleção de qual modelos estatísticos testado é utilizado para cada DFU, estabeleceu-se um modelo de aferição da acuracidade na base de teste, baseado no indicador de desempenho conhecido como “*Mean Absolute Percentual Error*” (MAPE).

O MAPE pode ser calculado obtendo-se a diferença entre o previsto e realizado para o período, em módulo, e dividindo-se essa diferença obtida pelo valor realizado no mesmo período, tendo-se assim um percentual de inacuracidade da previsão realizada.

Após a modelagem e da obtenção da previsão para cada DFU no dataset de teste, elege-se o modelo de séries temporais e “machine learning” que conseguiu obter o menor MAPE, como o modelo pré-disposto àquele DFU.

A tabela 5 apresenta o resultado dos modelos aplicados pela quantidade percentual de DFU's. Percebe-se que os modelos de séries temporais se adequaram melhor a um significativo percentual dos produtos, com destaque para Holt (“Double Exponential Smoothing”) e Arima (Box-Jenkins).

Tabela 5. Ranking de modelos

Método	% DFU's
Double Exponential Smoothing	33,0%
Arima Model	26,3%
Single Exponential Smoothing	10,3%
Croston Model	8,7%
Linear Regression	7,3%
Simple Moving Average	4,0%
Triple Exponential Smoothing	2,0%
Radial Basis Function	1,3%
Bayesian Neural Network	1,3%
XG Boosting Classifier	1,3%
Prophet Model	1,0%
Multiple Linear Regression	0,7%
Multi Layer Perceptron	0,3%

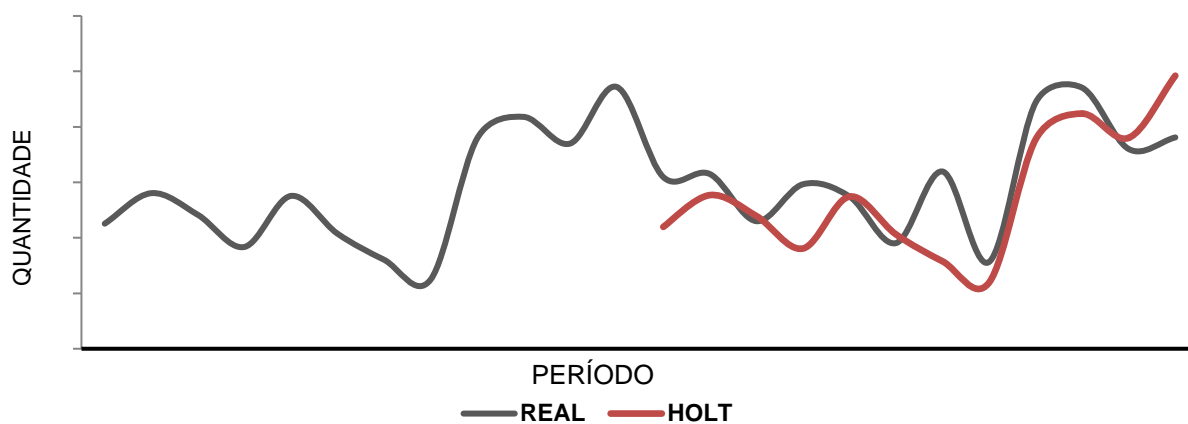
Naive Bayes	0,3%
Random Forest	0,3%
LSTM	0,3%
Weighted Moving Average	0,3%
Support Vector Machines	0,3%
Bass Difusion	0,3%
Support Vector Regression	0,3%

Fonte: Dados originais da pesquisa

Notou-se que os modelos de Suavização Exponencial Dupla (Holt) e Arima (Box-Jenkins) foram os modelos que melhor apresentaram resultados, menos tendenciosos e mais precisos para a maior parte dos produtos do portfólio.

O modelo Holt costuma ser apropriado quando os dados mostram que há uma tendência. A suavização exponencial dupla considera dois componentes, sendo um chamado de nível, que é uma estimativa suavizada do valor dos dados no final de cada período, e o outro é a tendência, que consiste em uma estimativa suavizada do crescimento médio no final de cada período. Um exemplo de um DFU que em que o modelo Holt foi o modelo que apresentou menor erro consta no gráfico 1:

Gráfico 1: Exemplo de DFU com Holt

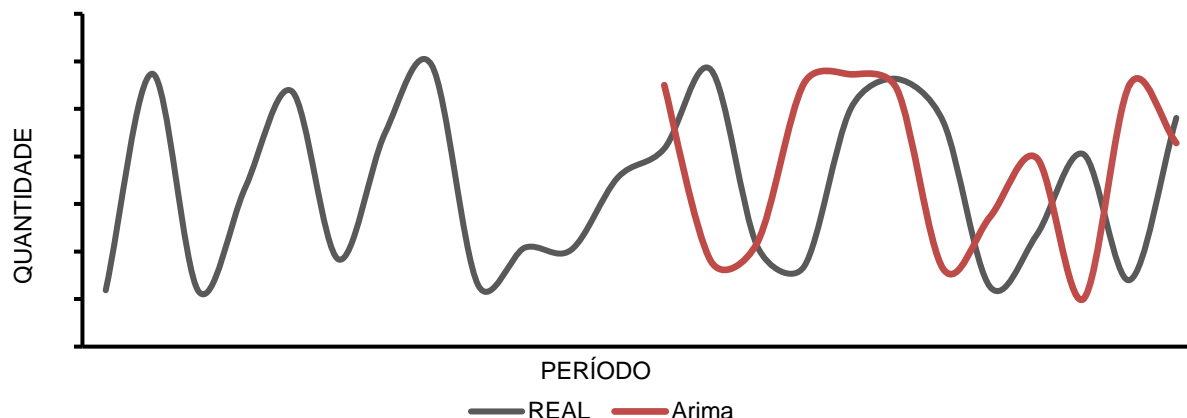


Fonte: Dados originais da pesquisa

O modelo Arima é um modelo difundido pelos pesquisados Box e Jenkins desde 1976, apropriado para séries não estacionárias, ou seja, séries em que a média não é constante no período de análise, apresentando tendência e sazonalidade. O modelo Arima é constituído de três partes, sendo “p” relativo a ordem da auto regressão, “d” relativo a ordem de diferenciação, e “q” relativo a ordem da média móvel.

Para se calcular os melhores parâmetros (p,d,q) para cada DFU, utilizou-se um loop de testagem através de laços “for”. Um exemplo de DFU que obteve melhor performance de previsão através do modelo Arima pode ser visualizado no gráfico 2:

Gráfico 2. Exemplo de DFU com Arima



Fonte: Dados originais da pesquisa

Há indícios também a falta de dados correlacionados à demanda dos produtos impacta a qualidade das previsões de modelos de “machine learning”, onde destacam-se sendo modelos promissores para o portfólio: “Bayesian Neural Network”, “XG Boosting” e “Prophet”.

3.2.7 Previsão de demanda

Sabendo-se qual o modelo que apresentou melhor performance preditiva na base de teste, ou seja, menor MAPE para o DFU, volta-se a considerar o histórico como um único “dataset”, ou seja, deixa-se de considerar 2 “datasets”, treino e teste, e com base no histórico completo aplica-se para cada DFU o modelo escolhido de melhor performance para realizar a previsão para o horizonte futuro desejado.

3.2.8 Aferição de acuracidade

Através da combinação das previsões produzidas por diferentes algoritmos é possível aumentar a acuracidade e precisão da demanda (Papacharalampous et al., 2018)

Após realizadas as previsões, acompanha-se o realizado versus o previsto através do indicador WMAPE, o que servirá de base para melhoria contínua do processo, alertando para oportunidades de melhor calibragem e testagem dos modelos propostos, ou mesmo abertura do estudo para buscar novos modelos desenvolvidos e aprimorados continuamente no âmbito da análise e ciência de dados.

O WMAPE, por sua vez, é a sigla para “Weighted Mean Absolute Percentual Error”. A sua fórmula de cálculo pode ser exemplificada pela fórmula 1, onde soma-se a

diferença absoluta entre o realizado e o previsto de demanda de cada produto e, divide-se esta soma pelo somatório do realizado de demanda de todos os produtos:

$$\frac{\sum |Realizado - Previsto|}{\sum Realizado} \quad (1)$$

Onde,

Realizado: é a demanda real de cada DFU em determinado período; Previsto: é a previsão de demanda que o DFU possuía para determinado período.

4 RESULTADOS E DISCUSSÃO

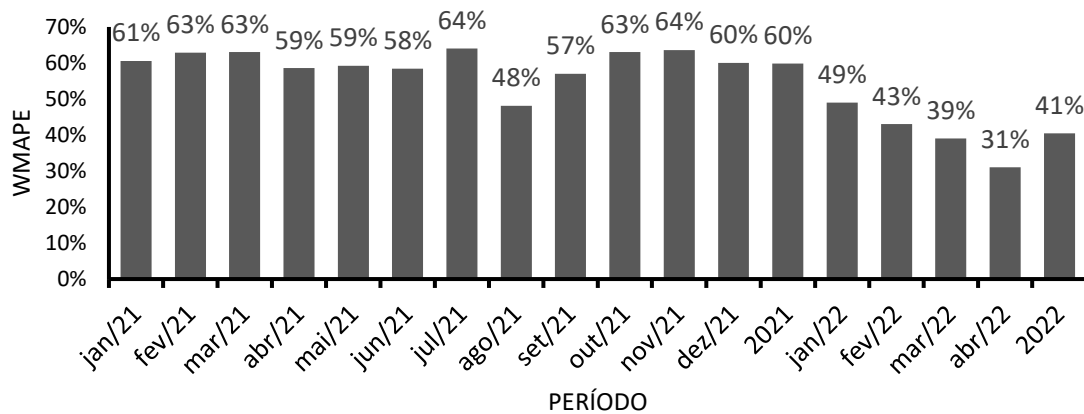
Lidar com dados tem se tornado um dos desafios mais relevantes para as organizações na atualidade. Os dados transformaram-se em um dos ativos mais valiosos que as empresas podem possuir, uma vez que sua disponibilidade está cada vez mais acessível e em diversos pontos da cadeia de suprimentos, desde o contato com o consumidor final até os elos mais iniciais. Entretanto, extrair informações de dados é o que leva a obtenção de vantagens competitivas.

Este trabalho apresentou uma nova perspectiva a empresa estudada em termos de performance na gestão da cadeia de suprimentos orientada a dados, através de aumento na acuracidade dos planos de vendas utilizando modelos de séries temporais e “machine learning” aplicados com apoio da linguagem Python.

Percebeu-se que houve um significativo incremento no grau de previsibilidade da empresa estudada, reduzindo o indicador de WMAPE de aproximadamente 60% para um novo patamar de 41%, representando uma melhoria de 19 pontos percentuais.

O gráfico 3 descreve os resultados do WMAPE na empresa pesquisada, no período entre Janeiro de 2021 e Dezembro de 2021, que é o período em que ainda não estava implementada a nova metodologia, e apresenta também o período de Janeiro de 2022 até Abril de 2022, que é o período no qual se percebe os resultados da pesquisa.

Gráfico 3. Histórico do WMAPE



Fonte: Dados originais da pesquisa

A melhoria obtida no indicador de WMAPE proporcionou ganhos para empresa pesquisada em termos de nível de serviço e redução de estoques. O nível de serviço ao cliente é medido como resultado da pontualidade e integralidade na entrega ao cliente, difundido como o indicador “On time In Full” [OTIF]. O OTIF é um indicador binário, onde o resultado do indicador para cada pedido de venda pode ser apenas 0 (zero) ou 1 (um). O cálculo se dá levando em consideração todos os pedidos que tiveram data prometida (ou desejada) de entrega para determinado período. Para cada pedido de venda, analisa-se se a data de entrega foi cumprida e se todos os produtos do pedido foram entregues na quantidade solicitada. Somente se estas duas condições foram cumpridas, então o pedido conta como positivo para o OTIF, ou seja, 1 (um). Após realizar essa análise para cada pedido no período em análise, verifica-se qual o percentual dos pedidos que tiveram pontuação 1 em relação ao número total de pedidos deste mesmo período, obtendo-se assim, o indicador de OTIF, conforma apresentado na fórmula 2.


$$\frac{\sum \text{Pedidos On Time e In Full}}{\sum \text{Pedidos}} \quad (2)$$

Onde,

Pedidos On Time: é a quantidade de pedidos que foram faturados dentro do prazo prometido e com integralidade dos itens e quantidade; Pedidos: é a quantidade total de pedidos do período analisado.

O gráfico 4 descreve os resultados do OTIF na empresa pesquisada, comparando os mesmos períodos. Percebe-se que em 2021 o indicador apresentou resultado médio de 71%, contra 78% em 2022.

Gráfico 4. Histórico do OTIF



Fonte: Dados originais da pesquisa

De forma análoga, observou-se uma evolução nos valores de capital de giro necessário para suportar o negócio. O capital de giro é um indicador empresarial que mensura o volume de capital monetário necessário para que a empresa cumpra suas obrigações, levando em conta que existe um prazo médio de pagamento oferecidos pelos fornecedores, um estoque interno necessário para minimizar custos, e um prazo médio de recebimento que a empresa concede aos seus clientes.

A empresa pesquisada costuma simplificar o cálculo do capital de giro através da fórmula 3:

$$CAPITAL DE GIRO = PMR + EST - PMP \quad (3)$$

Onde,

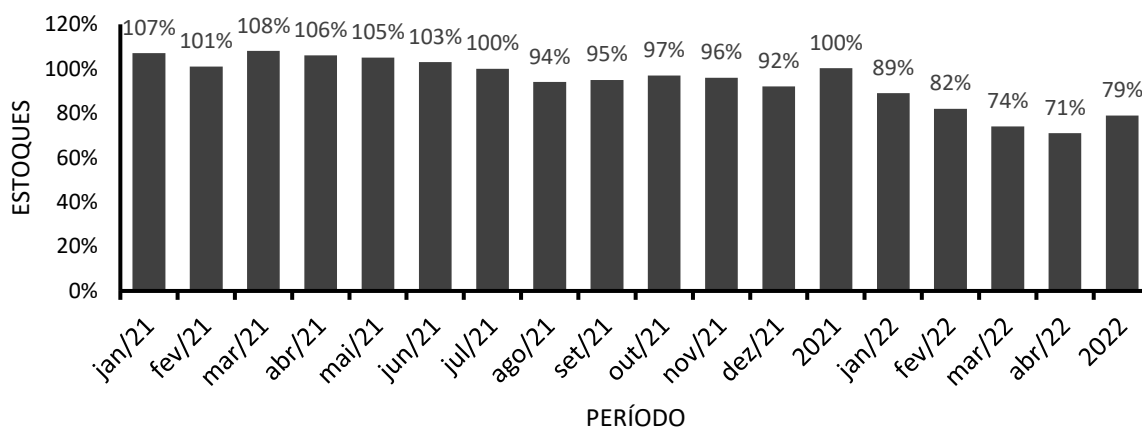
PMR: é o prazo médio de recebimento, entre o faturamento do pedido para o cliente até o recebimento total; EST: é a cobertura do estoque total da companhia, incluindo matéria-prima, produtos intermediários e produtos acabados; PMP: é o prazo médio de pagamento, entre o recebimento da nota fiscal de compra em estoque até o pagamento total do pedido.

Foi definido pela empresa que o grande impacto no capital de giro é o estoque, onde a empresa possui oportunidades na qualidade do estoque, ou seja, na distribuição das coberturas de estoque entre todos os itens. Percebe-se que existem produtos e matérias-primas com estoques acima do que seria necessário para suportar a operação de forma sustentável, e a somatória destes excedentes constitui-se em um volume monetário considerável e impactante no capital de giro. Estudos internos da empresa pesquisada elegem a acuracidade das previsões de demanda como o grande vilão do alto volume de

estoque, e consequente da alta necessidade de capital de giro. Como a empresa está inserida em um segmento com significativa volatilidade na demanda, e impacto de sazonalidade entre os meses do ano, e principalmente entre as semanas do mês, onde os últimos 10 (dez) dias do mês representam cerca de 50% do faturamento mensal, a empresa adota um sistema de produção nivelado, buscando antecipar os picos de demanda para ocupar a capacidade produtiva nos momentos em que está atravessando os vales. Sem carteira em mãos nestes momentos, a empresa usa a previsão de demanda para apostar em que produtos e quantidade antecipar a produção. A baixa qualidade na previsão de demanda, consequentemente, resulta em excesso ou faltas de estoques, impactando de um lado o capital de giro, e de outro o nível de serviço ao cliente.

O gráfico 5 demonstra o histórico dos estoques da companhia. Por questões de confidencialidade da informação, foi tomado como estoque base de 01 de Janeiro de 2021 como 100%, e os demais meses estão correlacionados com esta base. Percebeu-se que houve uma redução de 21% no valor do estoque médio da companhia, se comparados os valores de 2021, antes da implementação desta pesquisa, com os valores médios de 2022, após a implementação da pesquisa.

Gráfico 5. Histórico do Estoque



Fonte: dados originais da pesquisa

5 IMPLICAÇÕES PRÁTICAS E GERENCIAIS

Após uma pesquisa na literatura, percebe-se que existe um gap da aplicação de TI no processo de S&OP, principalmente no processo de planejar a demanda. Desta maneira o presente artigo apresenta métodos estatísticos e modelos de ST e ML que podem ser aplicados no processo de S&OP de diferentes empresas.

Em relação a contribuições práticas, após a aplicação dos modelos de ST e ML a empresa estudada conseguiu aumentar sua acuracidade no processo de prever demanda, desta maneira conseguiu obter dados mais acurados para planejar sua cadeia produtiva e consequentemente obter melhores resultados e desempenho. Além do mais, o estudo pode fomentar novas pesquisas para estimular a utilização de TI no S&OP para contribuir na melhoria contínua do processo.

6 CONSIDERAÇÕES FINAIS

Neste trabalho, mostrou-se o quão importante é trabalhar com uma linguagem de programação específica, neste caso, Python, para manipular os dados e gerar simulações de diversos modelos para cada um dos itens do portfólio com velocidade computacional que permite repetir o processo quantas vezes for necessário ao longo de curtos períodos de tempos, o que, quando se possui somente o recurso das planilhas eletrônicas como ferramenta para o processo de previsão de vendas, torna-se inviável.

Em um portfólio de produtos tão completo quanto na empresa estudada, percebe-se claramente que o comportamento de demanda entre cada família de produtos é significativamente diferente no que tange ao coeficiente de variação e grau de intermitência, fazendo com que a performance de previsão varie entre os modelos estatísticos. A possibilidade de calibração de parâmetros de cada modelo estatístico para cada produto é inviável de forma manual, por isso o diferencial de utilizar capacidades computacionais a favor do processo.

Neste estudo, percebeu-se a importância do processo S&OP para as empresas, principalmente no contexto mercadológico atual, de volatilidade na demanda e na oferta, complementado por componentes inflacionários e altas taxas de juros. Dentro desse processo, percebeu-se a diferença que a previsão de demanda faz, sendo o principal dado de entrada, sabendo-se que a qualidade da saída do processo, depende em muito da qualidade da entrada. Através do melhor aproveitamento dos dados, foi possível elevar o patamar das previsões de demanda, reduzindo os erros, e por consequência obtendo resultados significativos em termos de capital de giro e nível de serviço ao cliente.

Importante ressaltar que há outros benefícios que não foram medidos, como por exemplo o montante de vendas perdidas. Através deste trabalho, obteve-se um estoque mais saudável, e consequentemente maior agilidade e confiabilidade na entrega dos pedidos, fazendo com que clientes com demanda urgentes não deixem de comprar da empresa por falta de estoques. Da mesma forma, a margem de contribuição das vendas

também não foi possível de medir neste trabalho, mas relatos internos constataam melhorias, uma vez que, na disposição de estoques mais alinhados com a demanda de mercado, passou-se a aproveitar as ineficiências dos concorrentes e obter maior poder de negociação com clientes, afoitos pelas entregas imediatas que a empresa passou a oferecer com mais constância.

REFERÊNCIAS

APICS.2018. Certified in Production and Inventory Management: Learning System. APICS, Chicago.

Ben Ali, M., D'Amours, S., Gaudreault, J. et al. (2019), "Integrating revenue management and sales and operations planning in a Make-To-Stock environment: softwood lumber case study", *INFOR: Information Systems and Operational Research*, Taylor & Francis, Vol. 57, No. 2, pp. 314-41. <http://dx.doi.org/10.1080/03155986.2018.1554420>.

Boser, B.E., Guyon, I.M. and Vapnik, V.N., 1992, July. A training algorithm for optimal margin classifiers. In *Proceedings of the fifth annual workshop on Computational learning theory* (pp. 144-152).

Büttner, D., Rabe, M., 2021. "sales forecasting in the electrical industry - an illustrative comparison of time series and machine learning approaches," 2021 9th international conference on traffic and logistic engineering (ictle)

Cadavid J.P.U, Iamouri S., Grabot B. 2018. Trends in Machine Learning Applied to Demand & Sales Forecasting: A Review. International Conference on Information Systems, Logistics and Supply Chain

Coelho, L., Richert, W. 2015. Building Machine Learning Systems with Python. Packt Publishing Ltd

Chen, I.F. and Lu, C.J., 2017. Sales forecasting by combining clustering and machine-learning techniques for computer retailing. *Neural Computing and Applications*, 28, pp.2633-2647.

Christopher, M. 2011. Logistics and Supply Chain Management, 4th edition. Financial Times Prentice Hall, Harlow

Fix, E., 1985. *Discriminatory analysis: nonparametric discrimination, consistency properties* (Vol. 1). USAF school of Aviation Medicine.

Forsyth, D.A., Mundy, J.L., di Gesù, V., Cipolla, R., LeCun, Y., Haffner, P., Bottou, L. and Bengio, Y., 1999. Object recognition with gradient-based learning. *Shape, contour and grouping in computer vision*, pp.319-345.

Goh, S.H. and Eldridge, S. (2019), "Sales and Operations Planning: The effect of coordination mechanisms on supply chain performance", *International Journal of Production Economics*, Vol. 214, pp. 80-94. <http://dx.doi.org/10.1016/j.iipe.2019.03.027>.

Grimson, J.A. and D.F. Pyke, Sales and operations planning: an exploratory study and framework. *The International Journal of Logistics Management*, 2007.

Ho, T.K., 1995, August. Random decision forests. In *Proceedings of 3rd international conference on document analysis and recognition* (Vol. 1, pp. 278-282). IEEE.

Hochreiter, S. and Schmidhuber, J., 1997. Long short-term memory. *Neural computation*, 9(8), pp.1735-1780.

Huang, G., Huang, G.B., Song, S. and You, K., 2015. Trends in extreme learning machines: A review. *Neural Networks*, 61, pp.32-48.

Hunt, E.B., Marin, J. and Stone, P.J., 1966. Experiments in induction.

James, G., Witten, D., Hastie, T. and Tibshirani, R., 2013. *An introduction to statistical learning* (Vol. 112, p. 18). New York: springer.

Kwak, Sang & Kim, Jong. 2017. Statistical data preparation: Management of missing values and outliers. *Korean Journal of Anesthesiology*

Kjellsdotter Ivert, L. K. et al. (2015a), "Sales and operations planning: responding to the needs of industrial food producers", *Production Planning & Control*, Vol. 26, pp. 280-295.

Kohonen, T., 1982. Self-organized formation of topologically correct feature maps. *Biological cybernetics*, 43(1), pp.59-69.

Kristensen, J. and P. Jonsson, Context-based sales and operations planning (S&OP) research. *International Journal of Physical Distribution & Logistics Management*, 2018. 48(1): p. 19-46.

Lapide, L. (2004), "Sales and Operations Planning Part I: The Process", *The Journal of Business Forecasting*, Fall-2004, pp. 17-19.

Lim, L.L., Alpan, G. and Penz, B. (2017), "A simulation-optimization approach for sales and operations planning in build-to-order industries with distant sourcing: Focus on the automotive industry", *Computers & Industrial Engineering*, Vol. 112, pp. 469-82. <http://dx.doi.org/10.1016/j.cie.2016.12.002>.

Mishra, D., Gunasekaran, A., Papadopoulos, T. et al.(2016), "Big Data and Supply Chain Management: a review and bibliometric analysis", *Annals of Operations Research*, Vol. 270, No. 1-2, pp. 313-36. <http://dx.doi.org/10.1007/s10479-016-2236-y>.

Oliva, R., Watson, N. 2011. Cross-functional alignment in supply chain planning: a case study of sales and operations planning, *Journal of Operations Management*, Vol. 29 No. 5

Nicolas, F.N.P., Thomé, A.M.T. and Hellingrath, B., 2021. Usage of information technology and business analytics within sales and operations planning: a systematic literature review. *Brazilian Journal of Operations & Production Management*, 18(3), pp.1-15

Papacharalampous, G., Tyralis, H. and Koutsoyiannis, D., 2018. Univariate time series forecasting of temperature and precipitation with a focus on machine learning algorithms: A multiple-case study from Greece. *Water resources management*, 32(15), pp.5207-5239.

Pavlyshenko, B.M., 2019. Machine-learning models for sales time series forecasting. *Data*, 4(1), p.15.

Pedroso, C.B., A.L. da Silva, and W.L. Tate, Sales and Operations Planning (S&OP): Insights from a multi-case study of Brazilian Organizations. *International Journal of Production Economics*, 2016. 182: p. 213-229

Ohlson, N.-E., J. Bäckstrand, and M. Riveiro, Artificial Intelligence-enhanced Sales & Operations Planning in an Engineer-to-order context, in *PLAN Utvecklings konferens* 2021. 2021: Borås

Rumelhart, D.E., Hinton, G.E. and Williams, R.J., 1986. Learning representations by back-propagating errors. *nature*, 323(6088), pp.533-536.

Scavarda, L.F., Hellingrath, B., Kreuter, T., Thomé, A.M.T., Seeling, M.X., Fischer, J.H. and Mello, R., 2017. A case method for Sales and Operations Planning: a learning experience from Germany. *Production*, 27.

Schmidt, A., Kabir, M.W.U. and Hoque, M.T., 2022. Machine learning based restaurant sales forecasting. *Machine Learning and Knowledge Extraction*, 4(1), pp.105-130.

Seeling, M.X., Scavarda, L.F. and Thomé, A.M.T., 2019. A sales and operations planning application in the Brazilian subsidiary of a multinational chemical company. *Brazilian Journal of Operations & Production Management*, 16(3), pp.424-435.

Sherstinsky, A., 2020. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network. *Physica D: Nonlinear Phenomena*, 404, p.132306.

Thomassey, S., 2010. Sales forecasts in clothing industry: The key success factor of the supply chain management. *International Journal of Production Economics*, 128(2), pp.470-483.

Thomé, A. M. T. et al. (2012a), “Sales and Operations Planning: a research synthesis”, *International Journal of Production Economics*, Vol. 138, No. 1, pp. 1-13.

Tugay, Resul and Şule Gündüz Öğüdücü. 2017. “Demand Prediction using Machine Learning Methods and Stacked Generalization.”

Wallace, T.F.; Stahl, R.A. 2003. *Previsão de Vendas: uma nova abordagem*. Trad: Daniel Gasnier. São Paulo: IMAM